

Análise Exploratória de Dados do SIH/SUS em Minas Gerais

Aplicação de Engenharia de Dados e AED em dados reais do DATASUS



Processamento de Dados
DBC → DBF → Parquet



Volume de Dados
~67,6 Milhões de Registros

EQUIPE

Felipe Lazzarini Cunha • Lucas Castro Carvalho • Pedro Detoni Pereira

Metodologia e Processamento dos Dados



Coleta de Dados

Portal DATASUS: [Extração de dados do SIH/SUS](#).



Transformação

[Scripts Python](#) para conversão de arquivos e [otimização em Parquet](#).



Processamento

[Consolidação e limpeza](#) com Pandas, NumPy e Matplotlib.

Validação e Preparação Final

Garantia de [integridade da base](#) para análise exploratória através de processos rigorosos de validação e limpeza de dados.

Resultados da Análise Exploratória

67,6M

Registros e 41
Colunas

164M

Atos Profissionais


4,9M

Duplicatas
Identificadas


Principais Insights

- Distribuição assimétrica e presença de outliers
- Correlação negativa fraca entre dias e valor


Resultados da Análise Exploratória:




Resultados da Análise Exploratória:




Resultados da Análise Exploratória:




Resultados da Análise Exploratória:




Resultados da Análise Exploratória:




Resultados da Análise Exploratória:




Resultados da Análise Exploratória:




Resultados da Análise Exploratória:



Resultados da Análise Exploratória:



Resultados da Análise Exploratória:



Resultados da Análise Exploratória:



Resultados da Análise Exploratória:

Dimensão da base:

Linhas: 67,678,358

Colunas: 41

Duplicatas completas:

4,936,049

Principais indicadores:

	indicador	valor
	valor_total_ato	9.302797e+09
	valor_medio_ato	1.374560e+02
	valor_mediano_ato	1.110000e+00
	total_atos_profissionais	1.640497e+08
	total_procedimentos	1.481209e+08
	aih_unicas	4.828171e+06
	estabelecimentos_unicos_cnes	5.100000e+02
	atos_profissionais_unicos	3.138000e+03
	cid_principal_unicos	9.297000e+03

Resultados da Análise Exploratória:

Tipos de dados:

SP_GESTOR	string
SP_UF	string
SP_AA	Int64
SP_MM	Int64
SP_CNES	string
SP_NAIH	string
SP_PROCREA	string
SP_DTINTER	string
SP_DTSAIDA	string
SP_NUM_PR	string
SP_TIPO	string
SP_CPFCGC	string
SP_ATOPROF	string
SP_TP_ATO	string
SP_QTD_ATO	int64
SP_PTSP	string
SP_NF	string
SP_VALATO	float64
SP_M_HOSP	string
SP_M_PAC	string
SP_DES_HOS	string
SP_DES_PAC	string
SP_COMPLEX	string
SP_FINANC	string
SP_CO_FAEC	string
SP_PF_CBO	string
SP_PF_DOC	string
SP_PJ_DOC	string
IN_TP_VAL	string
SEQUENCIA	int64
REMESSA	string
SERV_CLA	string
SP_CIDPRI	string
SP_CIDSEC	string
SP_QT_PROC	int64
SP_U_AIH	string
SP_DTINTER_DATA	datetime64[us]
SP_DTSAIDA_DATA	datetime64[us]
SP_NF_DATA_POSSIVEL	datetime64[s]
COMPETENCIA	datetime64[us]
DIAS_INTERNAcao	int64

RangeIndex: 67678358 entries, 0 to 67678357

Data columns (total 41 columns):

#	Column	Dtype
0	SP_GESTOR	string
1	SP_UF	string
2	SP_AA	Int64
3	SP_MM	Int64
4	SP_CNES	string
5	SP_NAIH	string
6	SP_PROCREA	string
7	SP_DTINTER	string
8	SP_DTSAIDA	string
9	SP_NUM_PR	string
10	SP_TIPO	string
11	SP_CPFCGC	string
12	SP_ATOPROF	string
13	SP_TP_ATO	string
14	SP_QTD_ATO	int64
15	SP_PTSP	string
16	SP_NF	string
17	SP_VALATO	float64
18	SP_M_HOSP	string
19	SP_M_PAC	string
20	SP_DES_HOS	string
21	SP_DES_PAC	string
22	SP_COMPLEX	string
23	SP_FINANC	string
24	SP_CO_FAEC	string
25	SP_PF_CBO	string
26	SP_PF_DOC	string
27	SP_PJ_DOC	string
28	IN_TP_VAL	string
29	SEQUENCIA	int64
30	REMESSA	string
31	SERV_CLA	string
32	SP_CIDPRI	string
33	SP_CIDSEC	string
34	SP_QT_PROC	int64
35	SP_U_AIH	string
36	SP_DTINTER_DATA	datetime64[us]
37	SP_DTSAIDA_DATA	datetime64[us]
38	SP_NF_DATA_POSSIVEL	datetime64[s]
39	COMPETENCIA	datetime64[us]
40	DIAS_INTERNAcao	int64

dtypes: Int64(2), datetime64[s](1), datetime64[us](3), float64(1), int64(4), string(30)

Resultados da Análise Exploratória:

Resumo estatístico das variáveis numéricas:

	count	mean	std	min	25%	50%	75%	max
SP_AA	67678358.0	2024.177532	0.909601	2023.0	2023.0	2024.0	2025.0	2026.0
SP_MM	67678358.0	6.296792	3.529544	1.0	3.0	6.0	9.0	12.0
SP_QTD_ATO	67678358.0	2.423961	5.338767	0.0	1.0	1.0	2.0	999.0
SP_VALATO	67678358.0	137.456011	767.788153	0.0	0.0	1.11	65.0	149825.44
SEQUENCIA	67678358.0	3766.604728	5933.517738	1.0	258.0	998.0	4207.0	31763.0
SP_QT_PROC	67678358.0	2.188601	5.326323	0.0	1.0	1.0	2.0	999.0
DIAS_INTERNAO	67678358.0	8.559929	22.930211	0.0	2.0	5.0	11.0	5901.0

Resumo das variáveis categóricas:

	count	unique	top	freq
SP_GESTOR	67678358	371	310620	12540162
SP_UF	67678358	1	31	67678358
SP_CNES	67678358	510	0027014	3149429
SP_NAIIH	67678358	4828171	3124120963360	754
SP_PROCREA	67678358	1689	0303010037	4236966
SP_DTINTER	67678358	1448	20250630	81502
SP_DTSaida	67678358	1308	20251031	97221
SP_NUM_PR	67678358	1		67678358
SP_TIPO	67678358	1		67678358
SP_CPFCGC	67678358	3497	00000000027014	2913344
SP_ATOPROF	67678358	3138	0301010170	2940476
SP_TP_ATO	67678358	1		67678358
SP_PTSP	67678358	288	0	58530190
SP_NF	67678358	342043		66488432
SP_M_HOSP	67678358	371	310620	12540162
SP_M_PAC	67678358	3289	310620	6590097
SP_DES_HOS	67678358	2	0	67201204
SP_DES_PAC	67678358	2	0	39995106
SP_COMPLEX	67678358	2	02	59930028
SP_FINANC	67678358	5	06	61574193
SP_CO_FAEC	67678358	26		62643685
SP_PF_CBO	67678358	108	000000	47797022
SP_PF_DOC	67678358	39588	00000000000000	47797022
SP_PJ_DOC	67678358	1917	00000000000000	9091425
IN_TP_VAL	67678358	6	1	53630814
REMESSA	67678358	11801	HM31062001N202510.DTS	423890
SERV_CLA	67678358	125	000000	58825265
SP_CIDPRI	67678358	9297	0800	2122463
SP_CIDSEC	67678358	1	0000	67678358
SP_U_AIH	67678358	2	0	62828955

Resultados da Análise Exploratória:

Valores faltantes:

	coluna	qtd_faltantes	percentual_faltantes
38	SP_NF_DATA_POSSIVEL	67678358	100.0
1	SP_UF	0	0.0
2	SP_AA	0	0.0
3	SP_MM	0	0.0
4	SP_CNES	0	0.0
5	SP_NAIH	0	0.0
6	SP_PROCREA	0	0.0
7	SP_DTINTER	0	0.0
0	SP_GESTOR	0	0.0
8	SP_DTSaida	0	0.0
9	SP_NUM_PR	0	0.0
11	SP_CPFCGC	0	0.0
10	SP_TIPO	0	0.0
13	SP_TP_ATO	0	0.0
14	SP_QTD_ATO	0	0.0
15	SP_PTSP	0	0.0
12	SP_ATOPROF	0	0.0
17	SP_VALATO	0	0.0
18	SP_M_HOSP	0	0.0
19	SP_M_PAC	0	0.0
20	SP_DES_HOS	0	0.0
21	SP_DES_PAC	0	0.0
22	SP_COMPLEX	0	0.0
23	SP_FINANC	0	0.0
16	SP_NF	0	0.0
24	SP_CO_FAEC	0	0.0
25	SP_PF_CBO	0	0.0
27	SP_PJ_DOC	0	0.0
26	SP_PF_DOC	0	0.0
29	SEQUENCIA	0	0.0
30	REMESSA	0	0.0
31	SERV_CLA	0	0.0
28	IN_TP_VAL	0	0.0
32	SP_CIDPRI	0	0.0
33	SP_CIDSEC	0	0.0
35	SP_U_AIH	0	0.0
34	SP_QT_PROC	0	0.0
36	SP_DTINTER_DATA	0	0.0
37	SP_DTSaida_DATA	0	0.0
39	COMPETENCIA	0	0.0
40	DIAS_INTERNACAO	0	0.0

Registros duplicados completos: 4,936,049

AIHs repetidas: 62,850,187

Observação: no arquivo SP é normal uma AIH aparecer mais de uma vez, pois pode conter vários atos profissionais.

Outliers pelo método IQR:

Resultados da Análise Exploratória:

Outliers pelo método IQR:

	coluna	q1	q3	iqr	limite_inferior	limite_superior	qtd_outliers	percentual_outliers
0	SP_AA	2023.0	2025.0	2.0	2020.0	2028.0	0	0.00
1	SP_MM	3.0	9.0	6.0	-6.0	18.0	0	0.00
2	SP_QTD_ATO	1.0	2.0	1.0	-0.5	3.5	9464609	13.98
3	SP_VALATO	0.0	65.0	65.0	-97.5	162.5	10153449	15.00
4	SEQUENCIA	258.0	4207.0	3949.0	-5665.5	10130.5	9068623	13.40
5	SP_QT_PROC	1.0	2.0	1.0	-0.5	3.5	8960701	13.24
6	DIAS_INTERNACAO	2.0	11.0	9.0	-11.5	24.5	4540117	6.71

Matriz de correlação:

	SP_AA	SP_MM	SP_QTD_ATO	SP_VALATO	SEQUENCIA	SP_QT_PROC	DIAS_INTERNACAO
SP_AA	1.000000	-0.167112	-0.008597	0.005935	-0.023338	-0.007727	0.000188
SP_MM	-0.167112	1.000000	-0.001063	0.004215	-0.039170	-0.001501	-0.000654
SP_QTD_ATO	-0.008597	-0.001063	1.000000	0.083503	0.013206	0.979554	0.137112
SP_VALATO	0.005935	0.004215	0.083503	1.000000	0.022971	0.068988	0.021441
SEQUENCIA	-0.023338	-0.039170	0.013206	0.022971	1.000000	0.010937	0.044614
SP_QT_PROC	-0.007727	-0.001501	0.979554	0.068988	0.010937	1.000000	0.117542
DIAS_INTERNACAO	0.000188	-0.000654	0.137112	0.021441	0.044614	0.117542	1.000000

Resultados da Análise Exploratória:

Regras de integridade:

	regra	qtd_invalidos	percentual_invalidos
0	SP_VALATO não deve ser negativo	0	0.0
1	SP_QTD_ATO não deve ser negativo	0	0.0
2	SP_QT_PROC não deve ser negativo	0	0.0
3	SP_MM deve estar entre 1 e 12	0	0.0
4	SP_DTINTER deve ser uma data válida	0	0.0
5	SP_DTSAIDA deve ser uma data válida	0	0.0
6	Data de saída não deve ser anterior à internação	0	0.0
7	SP_UF deve ter 2 caracteres	0	0.0
8	SP_CNES deve ter 7 caracteres	0	0.0
9	SP_NAIH deve ter 13 caracteres	0	0.0

Possíveis Próximos Passos do Projeto:

Machine Learning em Saúde Pública

Previsão de custos hospitalares
Identificação de padrões de internação
Agrupamento de perfis de pacientes

Detecção de Anomalias

Identificação de registros suspeitos
Apoio à auditoria e controle de fraudes

Expansão da Base

Aplicação para outros estados
Inclusão de novos períodos
Integração com outras bases do DATASUS

Engenharia de Dados

Uso de Python e Parquet em larga escala
Automatização do pipeline de processamento