

Análise Exploratória de Dados do SIH/SUS em Minas Gerais Utilizando Python e Arquivos Parquet

Felipe Lazzarini Cunha - felipe.cunha@estudante.ufjf.br

Lucas Castro Carvalho - lucascastroeeeh@gmail.com

Pedro Detoni Pereira - pedrodetoni.pereira@estudante.ufjf.br

Departamento de Ciência da Computação - Universidade Federal de Juiz de Fora

Introdução

O Sistema de Informações Hospitalares do SUS (SIH/SUS) disponibiliza uma grande quantidade de dados relacionados a internações hospitalares, procedimentos médicos e atos profissionais realizados no sistema público de saúde brasileiro. Entretanto, devido ao elevado volume e à complexidade dos arquivos disponibilizados pelo DATASUS, torna-se necessária a utilização de técnicas computacionais para armazenamento, transformação e exploração dos dados. Este trabalho apresenta um processo completo de coleta, conversão, tratamento e análise exploratória de dados (EDA) utilizando informações do SIH/SUS referentes ao período entre janeiro de 2023 e março de 2026.

Metodologia

Os dados foram obtidos manualmente no portal DATASUS utilizando os arquivos do SIH/SUS disponibilizados no formato DBC. Inicialmente, os arquivos foram convertidos para DBF, formato que permite manipulação estruturada dos dados. Posteriormente, utilizando scripts desenvolvidos em Python, os arquivos DBF foram convertidos para o formato Parquet, visando maior desempenho de leitura, compressão e eficiência no processamento. Como os dados estavam separados em múltiplos arquivos mensais, foi desenvolvido um segundo script em Python para realizar a consolidação de todos os arquivos Parquet em uma única base integrada. Após a consolidação, a base foi tratada utilizando as bibliotecas os, warnings, pandas, numpy e matplotlib.pyplot. Essas ferramentas permitiram realizar limpeza de dados, tratamento de tipos, verificação de integridade, identificação de duplicatas, análise estatística descritiva e geração de gráficos para apoio à exploração dos dados.

Resultados

A base consolidada resultou em aproximadamente 67,6 milhões de registros e 41 colunas relacionadas aos atos profissionais do SIH/SUS. Durante a análise, foram identificadas cerca de 4,9 milhões de duplicatas completas, além da presença de mais de 164 milhões de atos profissionais registrados. A análise estatística permitiu identificar distribuições assimétricas nos valores dos atos, bem como diferenças significativas entre média e mediana, indicando a presença de outliers e concentração de valores baixos em grande parte dos registros. Também foram realizadas verificações de integridade envolvendo datas, campos numéricos e códigos hospitalares,

não sendo encontrados registros inválidos nas principais regras definidas. A utilização do formato Parquet demonstrou ganhos relevantes de desempenho no processamento e manipulação de grandes volumes de dados quando comparado aos formatos originais.




Figura 1: Relação entre Dias de Internação e Valor do Ato (R\$). A nuvem de pontos evidencia a correlação de Spearman negativa e fraca entre as variáveis.

Considerações Finais

Os resultados demonstram a importância do uso de técnicas de engenharia e análise de dados para manipulação de bases governamentais em larga escala. A utilização de Python e do formato Parquet possibilitou maior eficiência no armazenamento, consolidação e exploração das informações do SIH/SUS. Além disso, a análise exploratória permitiu compreender padrões presentes na base de dados, identificar inconsistências e gerar indicadores relevantes para futuras aplicações em mineração de dados, aprendizado de máquina e análise preditiva em saúde pública. Como trabalhos futuros, pretende-se aplicar modelos de machine learning para detecção de padrões e previsão de custos hospitalares a partir dos dados analisados.

Referências

BRASIL. Ministério da Saúde. Departamento de Informática do SUS. Sistema de Informações Hospitalares do SUS (SIHSUS). Brasília: DATASUS, 2026. Disponível em: <https://datasus.saude.gov.br>.

